# MAYA - Visual Set

## Morgan

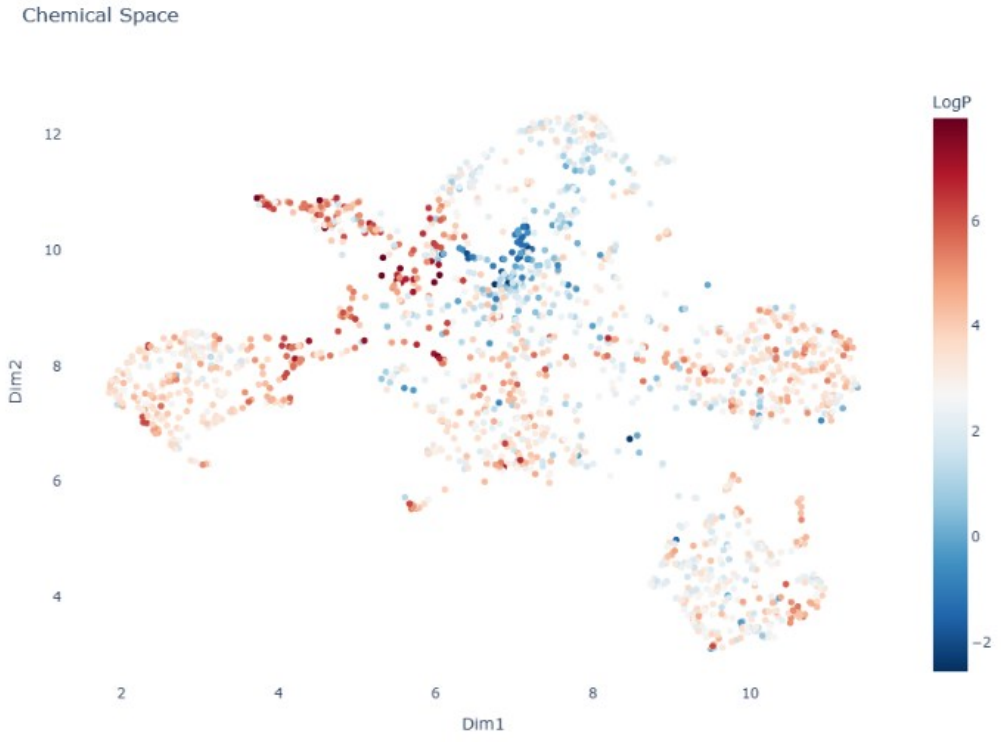
- PCA:
  Trustworthiness: 0.773
  Correlation: 0.457

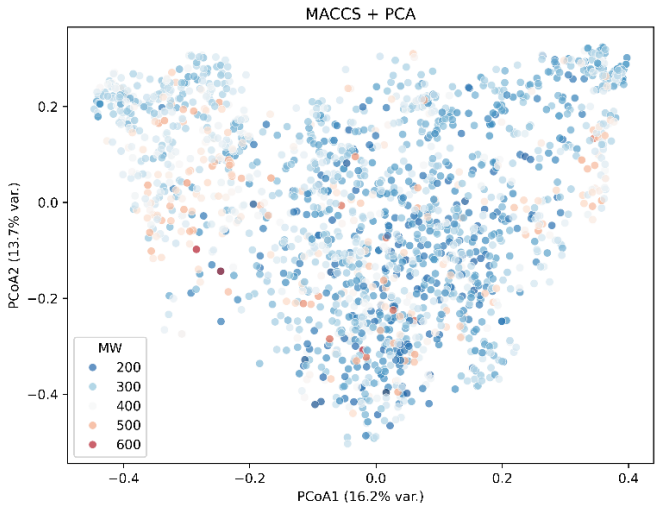
- t-SNE:
  Trustworthiness: 0.969
  Correlation: 0.366

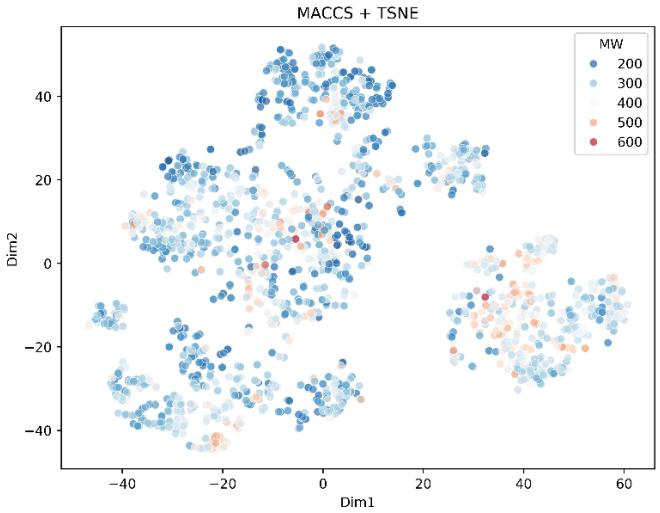
## MACCS

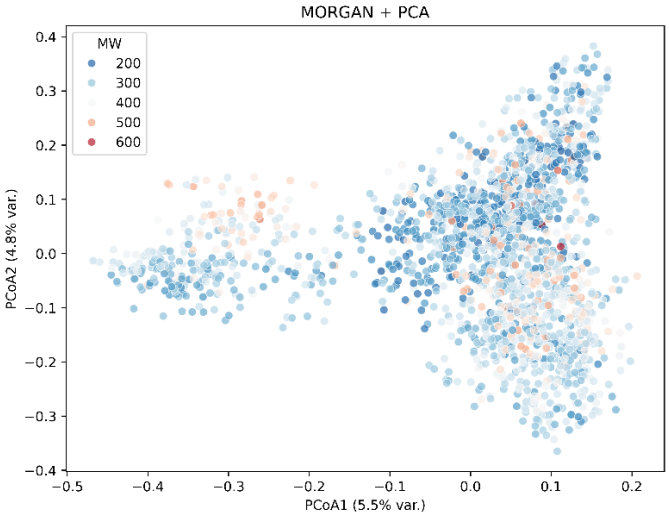
- PCA:
  Trustworthiness: 0.841
  Correlation: 0.643

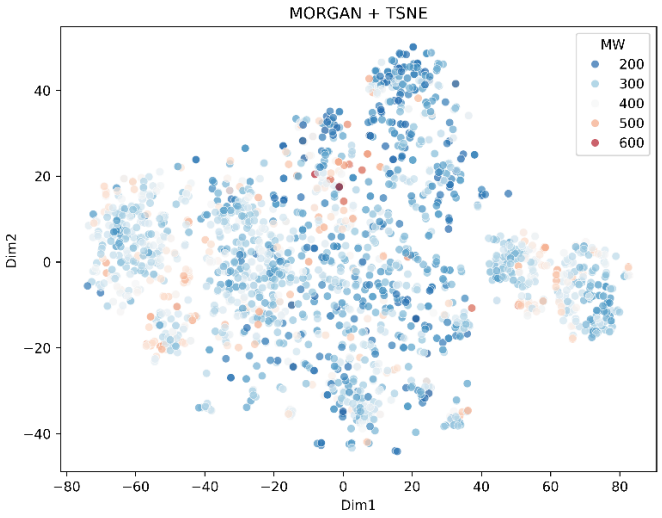
- t-SNE:
  Trustworthiness: 0.991
  Correlation: 0.474

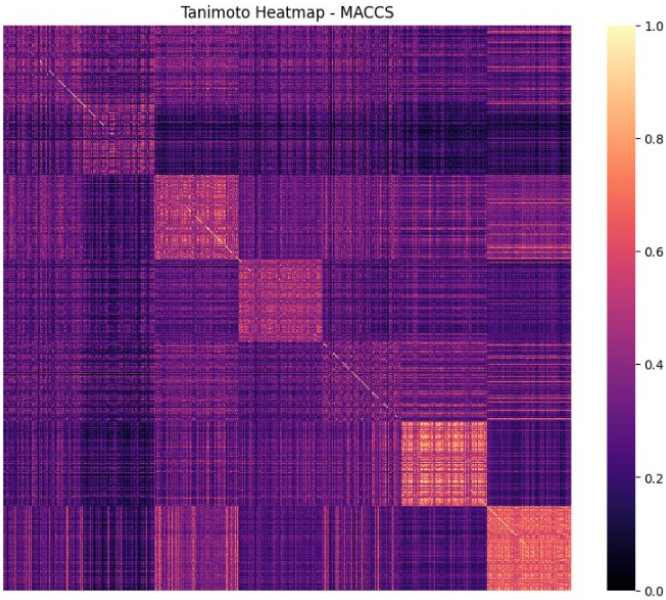


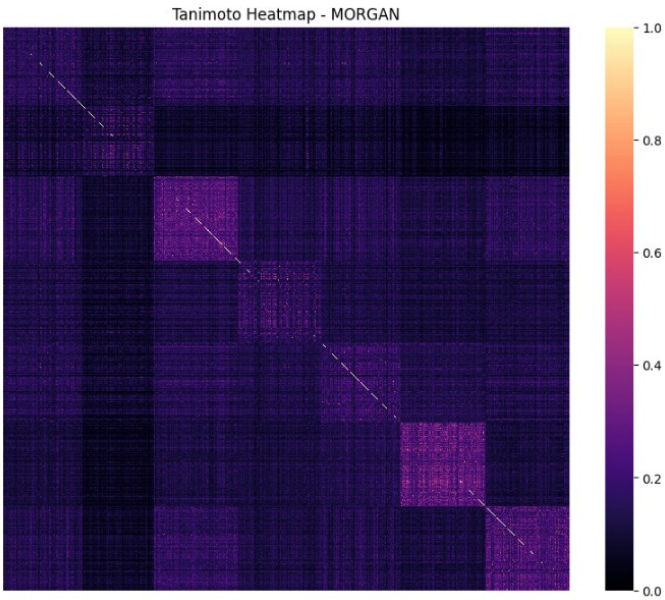

MACCS + PCA
PCoA2 (13.7% var.)
PCoA1 (16.2% var.)
MW
200
300
400
500
600


MACCS + TSNE
Dim2
Dim1
MW
200
300
400
500
600


MORGAN + PCA
PCoA2 (4.8% var.)
PCoA1 (5.5% var.)
MW
200
300
400
500
600


MORGAN + TSNE
Dim2
Dim1
MW
200
300
400
500
600


Tanimoto Heatmap - MACCS


Tanimoto Heatmap - MORGAN

# MAYA - Home Set

## Morgan

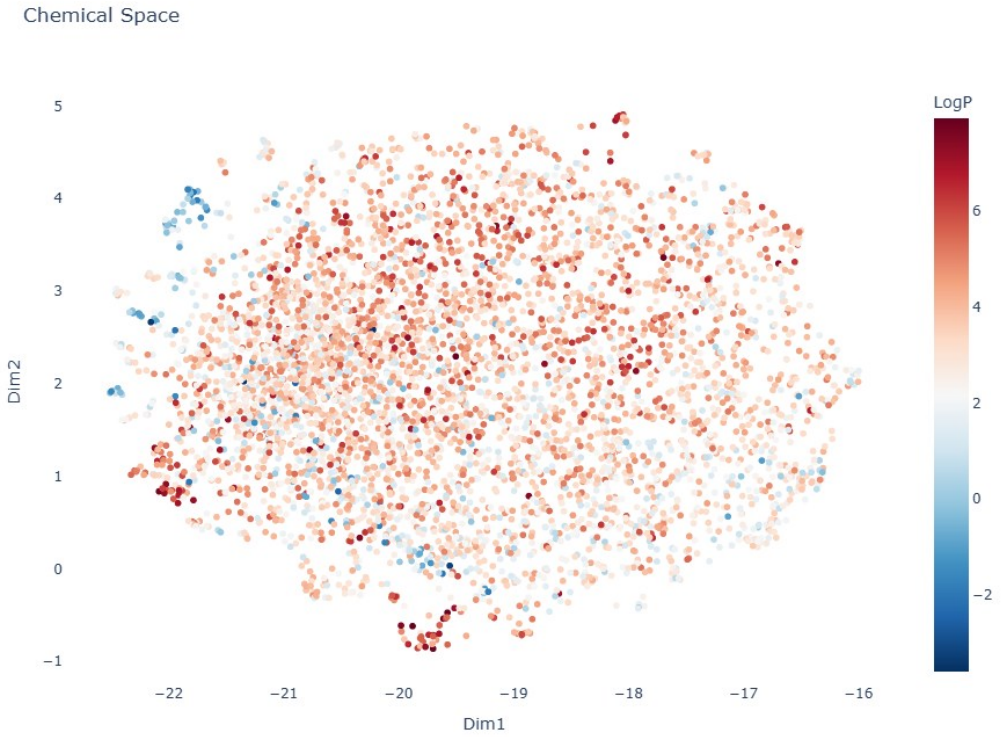
- PCA:
  Trustworthiness: 0.689
  Correlation: 0.315

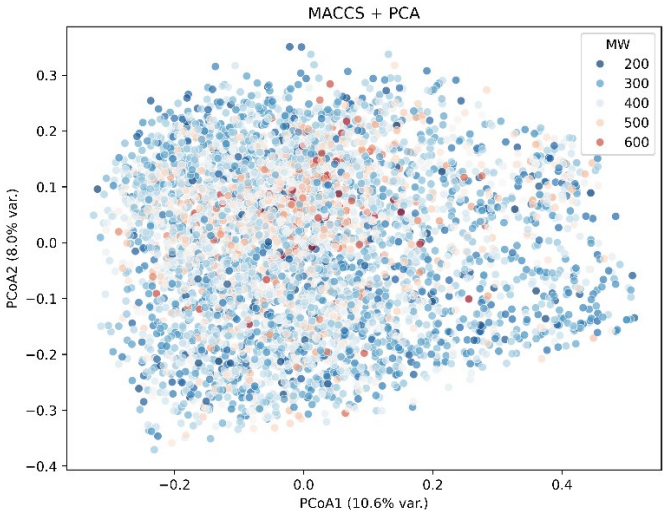
- t-SNE:
  Trustworthiness: 0.928
  Correlation: 0.340

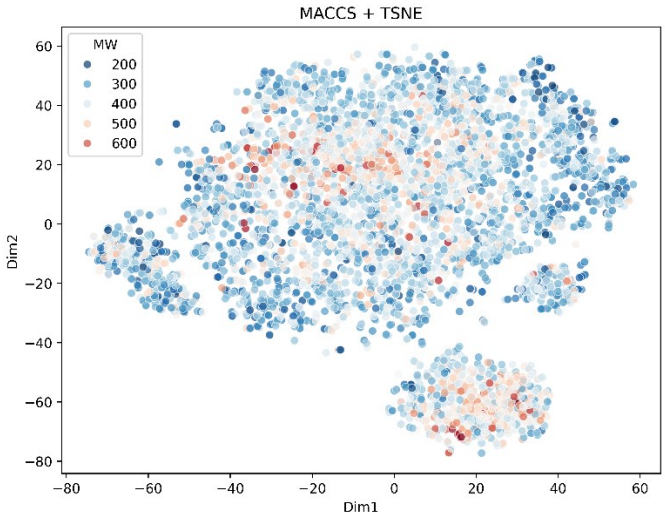
## MACCS

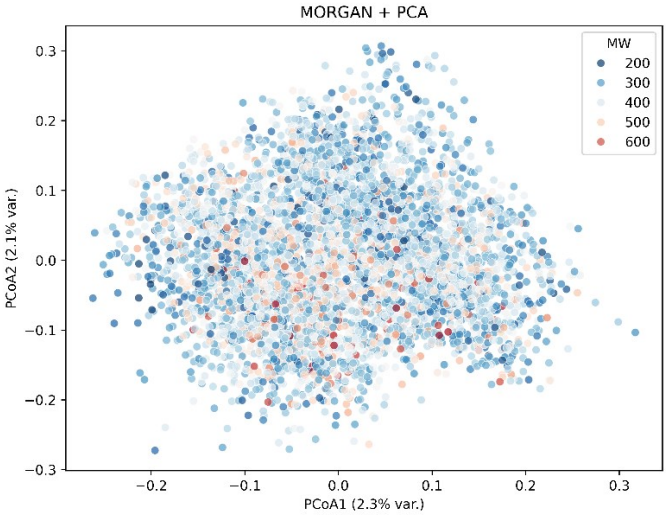
- PCA:
  Trustworthiness: 0.755
  Correlation: 0.602

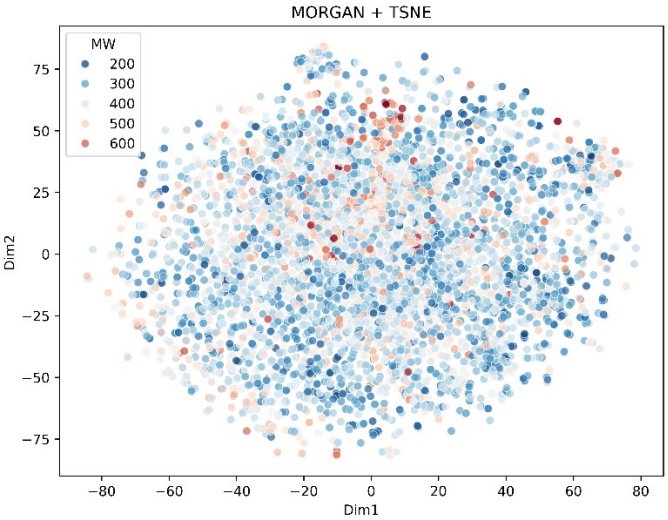
- t-SNE:
  Trustworthiness: 0.980
  Correlation: 0.549

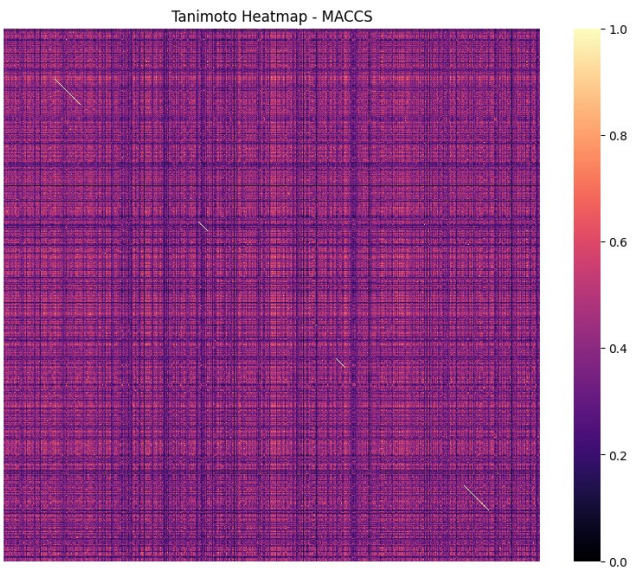


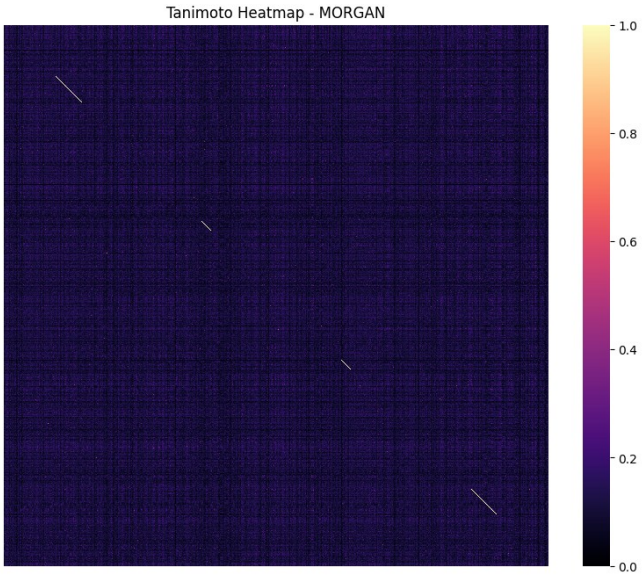

MACCS + PCA
MW
200
300
400
500
600
PCoA2 (8.0% var.)
PCoA1 (10.6% var.)


MACCS + TSNE
MW
200
300
400
500
600
Dim2
Dim1


MORGAN + PCA
MW
200
300
400
500
600
PCoA2 (2.1% var.)
PCoA1 (2.3% var.)


MORGAN + TSNE
MW
200
300
400
500
600
Dim2
Dim1


Tanimoto Heatmap - MACCS


Tanimoto Heatmap - MORGAN

# Análisis

**¿A qué se deben las diferencias observadas entre el visual set y el home set?**

Las diferencias entre ambos conjuntos se originan principalmente en la diversidad estructural.

En el visual set los heatmaps de similitud de Tanimoto revelan bloques diagonales bien definidos y ordenados por grupos de compuestos con alta similitud. Por el contrario, en el home set el heatmap es difuso y homogéneo, lo cual refleja una colección de datos sin agrupaciones evidente o con una dispersión molecular mucho más aleatoria.

En el visual set, tanto PCA como t-SNE muestran algunos agrupamientos y regiones con gradientes claros de MW, mayoritariamente en t-SNE. En cambio, en el home set, las moléculas forman una sola agrupación sin límites de clúster marcados, lo cual es de esperar en colecciones químicamente más heterogéneas (aunque si se ven algunos agrupamientos con MACCS + t-SNE).

La varianza explicada disminuye significativamente en el home set (por ejemplo, en Morgan pasa de 5.5% / 4.8% en el visual set a 2.3% / 2.1% en el home set). Esto evidencia que el home set tiene una dimensionalidad mucho mayor y mayor dispersión de características (mayor volumen de datos). También, las métricas de trustworthiness y correlation son consistentemente menores en el home set para PCA y t-SNE, indicando mayor complejidad estructural para proyectarlas a dos dimensiones.

**¿Qué diferencias esperas al calcular la similitud de Tanimoto utilizando huellas ECFP4 en comparación con MACCS?**

fingerprints MACCS Keys constan de diccionarios con 166 fragmentos. Al ser un diccionario relativamente pequeño (en comparación con ECFP4), muchas moléculas no relacionadas comparten varios de estos fragmentos, generando un coeficiente de Tanimoto mayor. En cambio, ECFP4 es un fingerprint topológico que captura mucha más información estructural (1024-2048 bits), lo que genera matrices de similitud mucho más dispersas y valores cercanos a 0 (fondo negro/morado oscuro).

ECFP4 es más sensible a modificaciones estructurales pequeñas. MACCS suele fallar en distinguir entre análogos cercanos que posean los mismos grupos funcionales generales o scaffolds.